

Metody analizy danych

Agnieszka Sołtys

Klasyfikacja

- scoring kredytowy,
- predykcja churnu - przewidywanie na podstawie cech klienta (opisujących m.in. jego zachowanie) czy klient odejdzie w najbliższym czasie (np. w ciągu miesiąca),
- rozpoznawanie choroby - rozpoznawanie na podstawie parametrów medycznych czy pacjent zachoruje lub jest chory,
- klasyfikacja tematyczna tekstu,
- rozpoznawanie zawartości obrazów.

Regresja logistyczna

- „Regresja” w nazwie pochodzi od podobieństwa do regresji liniowej, ale to model do klasyfikacji!
- Nazwa „logistyczna” pochodzi od funkcji logit używanej w modelu.

Zakładamy, że obserwacje y są niezależne i pochodzą z rozkładu Bernoulliego (dwupunktowego):

$$Y \sim \mathbf{B}(p(x)), \quad p(x) = \frac{1}{1 + \exp(-x^T \beta)},$$

czyli:

$$Y = \begin{cases} 1 & \text{z prawdopodobieństwem } p(x) \\ 0 & \text{z prawdopodobieństwem } 1 - p(x) \end{cases}$$


Predykcja dla nowych danych:

$$\hat{y} = \begin{cases} 1 & \text{jesli } p(x) \geq \frac{1}{2} \\ 0 & \text{jesli } p(x) < \frac{1}{2} \end{cases}$$

$$p(x) = \frac{1}{1 + \exp(-x^T \beta)} = \frac{1}{1 + \exp(4.1 - 1.5x)}$$

Np. dla Hours = 4, $p(4) = 0.87$, $\hat{y} = 1$.

Hours	Pass
1.75	1.00
2.00	0.00
2.25	1.00
2.50	0.00
2.75	1.00
...	...



Mamy dane n obserwacji (wielkość próby):

- X macierz planu dla p zmiennych objaśniających:

$$X = \begin{pmatrix} X_1 \\ \dots \\ X_n \end{pmatrix} = \begin{pmatrix} x_{11} & \dots & x_{1p} \\ \dots & \dots & \dots \\ x_{n1} & \dots & x_{np} \end{pmatrix}$$

- zmienną objaśnianą, $y_i \in \{0, 1\}$

$$y = \begin{pmatrix} y_1 \\ \dots \\ y_n \end{pmatrix}$$

Żeby dopasować model, trzeba znaleźć najlepsze wartości dla parametrów $\beta = \begin{pmatrix} \beta_1 \\ \dots \\ \beta_p \end{pmatrix}$. Estymatory $\hat{\beta}$ metody największej wiarygodności maksymalizują funkcję wiarygodności (optymalizacja numeryczna):

$$\mathbf{L}(\beta) = \prod_{i=1}^n (p(X_i))^{y_i} (1 - p(X_i))^{1-y_i}$$

Dodanie ograniczeń dla parametrów β (ściągnięcie).

- Regresja grzbietowa:

$$\hat{\beta}^{ridge} = \arg \max_{\beta} \mathbf{L}(\beta), \text{ pod warunkiem } \sum_{j=1}^p \beta_j^2 \leq t.$$

- LASSO (least absolute shrinkage and selection operator):
selekcja zmiennych

$$\hat{\beta}^{LASSO} = \arg \max_{\beta} \mathbf{L}(\beta), \text{ pod warunkiem } \sum_{j=1}^p |\beta_j| \leq t.$$

- Elastic Net: połączenie regresji grzbietowej i LASSO